

Inlämningsuppgift 4 - STAG36

Villiam Axtelius & Josie Sandell

May 2026

1 Inledning

Att välja en urvalsmetod är en viktig del av undersökningsdesign. Urvalsmetoden påverkar skattningens väntevärdesriktighet, precision, och bias, och vissa metoder är mer lämpliga än andra beroende på populationens egenskaper och undersökningens begränsningar. I denna rapport undersöker vi hur 1 032 182 röstberättigade röstade i Skåne under riksdagsvalet 2022. Vi använder 6 olika urvalsmetoder för att skatta andelen SD-röstare i Skåne: Obundet slumpmässigt urval (OSU), stratifierat urval med proportionell allokering, stratifierat urval med Neyman-allokering, systematiskt urval, tvåstegsurval med lika sannolikheter och tvåstegsurval med olika sannolikheter. Vi avslutar med att jämföra de olika metoderna och välja ett sätt att skatta resten av riksdagspartiernas röstandeler med.

2 Beskrivning av populationen


Datamaterialet består av samtliga 1 032 182 röstberättigade individer i Skåne vid riksdagsvalet 2022. För varje individ finns information om kommun, valdistriktskod, valdistriktsnamn, valkretskod, valkretsnamn och vilket parti individen röstade på. Personer som inte röstade har saknade värden på variabeln `Parti`.

För att kunna analysera stödet för Sverigedemokraterna skapades en indikatorvariabel för SD-röst enligt

$$SD_i = \begin{cases} 1, & \text{om individ } i \text{ röstade på Sverigedemokraterna,} \\ 0, & \text{om individ } i \text{ röstade på ett annat parti,} \\ NA, & \text{om individ } i \text{ inte röstade.} \end{cases}$$

I populationen fanns 212 455 individer som röstade på Sverigedemokraterna, 642 439 individer som röstade på något annat parti och 177 288 individer som inte röstade. Detta innebär att andelen SD-röstare bland samtliga röstberättigade var ungefär 20,58 procent. Eftersom de individer som inte röstade har saknade värden på parti används dock andelen SD-röstare bland de röstande som jämförelsevärde i analyserna. Den faktiska andelen SD-röstare bland de röstande i populationen är

$$p_{SD} = 0,2485.$$



Figur 1: Andel av de röstberättigade i Skåne som röstade på Sverigedemokraterna, röstade på ett annat parti eller inte röstade.

I Tabell 1 redovisas antalet röstberättigade i respektive valkrets.

Tabell 1: Antal röstberättigade per valkrets i Skåne.

Valkrets	Antal röstberättigade
Malmö kommun	251 172
Skåne läns norra och östra	244 489
Skåne läns södra	299 809
Skåne läns västra	236 712

Skåne består av fyra valkretsar och 33 kommuner. Malmö är den största kommunen sett till antalet röstberättigade, medan Perstorp är den minsta kommunen i materialet.

Tabell 2 visar röstandelarna för riksdagspartierna bland de röstande i populationen.

Tabell 2: Andel röster för riksdagspartierna bland de röstande i populationen.

Parti	Andel röster (%)
Socialdemokraterna	26,45
Sverigedemokraterna	24,85
Moderaterna	19,78
Vänsterpartiet	6,28
Centerpartiet	5,53
Miljöpartiet	4,86
Liberalerna	4,78
Kristdemokraterna	4,64

Med en bättre förståelse för populationen övergår vi nu till de olika urvalsmetoderna.

3 Obundet slumpmässigt urval

Den första urvalsmetoden som användes var obundet slumpmässigt urval utan återläggning. Ett urval om 1000 individer drogs från populationen. Vid ett obundet slumpmässigt urval har alla individer i populationen samma sannolikhet att bli inkluderade i urvalet.

Urvalet drogs med funktionen `sample()` i R. Därefter skapades ett survey-designobjekt med hjälp av paketet `survey`. Detta designobjekt användes sedan för att skatta andelen SD-röstare och skattningens medelfel.

3.1 Skattning med OSU

Tabell 3 visar skattningen av andelen SD-röstare med obundet slumpmässigt urval.

Tabell 3: Skattning av andelen SD-röstare med obundet slumpmässigt urval.

Storhet	Värde
Skattad andel SD-röstare	0,2424
Medelfel	0,0150

Skattningen blev 0,2424 och medelfelet blev 0,0150. Den faktiska andelen SD-röstare bland de röstande i populationen var 0,2485. Skattningen från det obundna slumpmässiga urvalet ligger därför relativt nära populationsvärdet, även om den är något lägre.

3.2 Efterstratifiering

Efter det obundna slumpmässiga urvalet genomfördes en efterstratifiering på kommunnivå. Efterstratifiering innebär att urvalet justeras med hjälp av känd information om populationens sammansättning. I detta fall användes kommun som efterstratifieringsvariabel.

Syftet med efterstratifiering är att förbättra precisionen i skattningen, särskilt om urvalets fördelning över kommuner skiljer sig från populationens faktiska fördelning. Eftersom kommun är en geografisk variabel som kan hänga samman med röstningsbeteende är den relevant att undersöka.

Tabell 4: Skattning av andelen SD-röstare efter efterstratifiering på kommun.

Storhet	Värde
Skattad andel SD-röstare	0,2452
Medelfel	0,0151

Efter efterstratifieringen blev skattningen 0,2452 och medelfelet 0,0151. Skattningen ligger något närmare populationsvärdet än den ursprungliga OSU-skattningen. Däremot förbättrades inte medelfelet, utan det blev i princip oförändrat.

Det är inte självklart att efterstratifiering på kommun är lämpligt i detta fall. Skåne har 33 kommuner, samtidigt som urvalet endast består av 1000 individer. Detta innebär att flera

kommuner kan representeras av få observationer i urvalet. När vissa efterstrata innehåller få observationer kan skattningarna inom dessa grupper bli instabila, vilket gör att efterstratifieringen inte nödvändigtvis förbättrar precisionen.

4 Stratifierat urval

I denna del genomfördes två geografiskt stratifierade urval. Populationen delades in i fyra strata, där varje valkrets i Skåne utgjorde ett stratum. Syftet med stratifiering är att säkerställa att samtliga valkretsar representeras i urvalet och att utnyttja känd struktur i populationen för att förbättra precisionen.

De fyra strata som användes var Malmö kommun, Skåne läns norra och östra, Skåne läns södra och Skåne läns västra. Dessa strata skiljer sig åt i storlek och kan även skilja sig åt i röstningsmönster. Därför är geografisk stratifiering rimlig att använda.

4.1 Proportionell allokering

Vid proportionell allokering fördelades stickprovsstorleken mellan strata i proportion till stratumens storlek. Om N_h betecknar antalet individer i stratum h , N populationens totala storlek och n stickprovsstorleken, ges allokeringen av

$$n_h = n \frac{N_h}{N}.$$

Eftersom det totala urvalet hade storlek $n = 1000$ fördelades observationerna ungefär proportionellt mot valkretsarnas storlek. Den proportionella allokeringen blev 243 individer från Malmö kommun, 237 individer från Skåne läns norra och östra, 291 individer från Skåne läns södra och 229 individer från Skåne läns västra.

Tabell 5: Proportionell allokering mellan valkretsarna.

Valkrets	Antal i urvalet
Malmö kommun	243
Skåne läns norra och östra	237
Skåne läns södra	291
Skåne läns västra	229

Efter att urvalet drogs skapades ett survey-designobjekt med valkrets som stratifieringsvariabel. Resultatet visas i Tabell 6.

Tabell 6: Skattning av andelen SD-röstare med stratifierat urval och proportionell allokering.

Storhet	Värde
Skattad andel SD-röstare	0,2443
Medelfel	0,0147

Skattningen med proportionell allokering blev 0,2443 och medelfelet blev 0,0147. Skattningen

ligger nära populationsvärdet 0,2485. Medelfelet är något lägre än medelfelet för OSU och OSU med efterstratifiering.

4.2 Neyman-allokering

Därefter genomfördes ett stratifierat urval med Neyman-allokering. Vid Neyman-allokering tas hänsyn både till stratumens storlek och variationen inom respektive stratum. Allokeringen ges av

$$n_h = n \frac{N_h S_h}{\sum_{h=1}^H N_h S_h},$$

där S_h är standardavvikelsen för undersökningsvariabeln inom stratum h . I detta fall är undersökningsvariabeln indikatorn för SD-röst.

Standardavvikelserna för SD-indikatorn i respektive valkrets redovisas i Tabell 7.

Tabell 7: Standardavvikelse för SD-indikatorn inom respektive valkrets.

Valkrets	Standardavvikelse
Malmö kommun	0,3685
Skåne läns norra och östra	0,4658
Skåne läns södra	0,4217
Skåne läns västra	0,4511

Eftersom kostnaden antas vara densamma i samtliga strata används Neyman-allokering utan kostnadsjustering. Metoden innebär att fler observationer placeras i strata där variationen är större. Den Neyman-allokerade fördelningen blev 210 individer från Malmö kommun, 259 individer från Skåne läns norra och östra, 288 individer från Skåne läns södra och 243 individer från Skåne läns västra.

Tabell 8: Neyman-allokering mellan valkretsarna.

Valkrets	Antal i urvalet
Malmö kommun	210
Skåne läns norra och östra	259
Skåne läns södra	288
Skåne läns västra	243

Resultatet från skattningen visas i Tabell 9.

Tabell 9: Skattning av andelen SD-röstare med stratifierat urval och Neyman-allokering.

Storhet	Värde
Skattad andel SD-röstare	0,2260
Medelfel	0,0144

Det stratifierade urvalet med Neyman-allokering gav en skattning på 0,2260 och ett medelfel på 0,0144. Medelfelet är lägre än för både OSU, OSU med efterstratifiering och proportionell allokering. Däremot blev skattningen i just detta urval lägre än populationsvärdet 0,2485. Detta visar att även en urvalsdesign med låg varians kan ge en realiserad skattning som avviker från populationsvärdet på grund av slumpvariation.

5 Systematiskt urval

I denna del genomfördes ett systematiskt urval. Vid systematiskt urval väljs först ett slumpmässigt startvärde. Därefter väljs var k :te individ i populationen.

Urvalsintervallet beräknades enligt

$$k = \left\lfloor \frac{N}{n} \right\rfloor,$$

där $N = 1\,032\,182$ är populationens storlek och $n = 1000$ är den önskade stickprovsstorleken. I råoutputen framgår att $k = 1032$. Det faktiska urvalet fick storlek 1018, vilket beror på hur det systematiska urvalet konstruerades utifrån startvärde och intervall.

Efter att urvalet drogs skapades ett survey-designobjekt och andelen SD-röstare skattades.

Tabell 10: Skattning av andelen SD-röstare med systematiskt urval.

Storhet	Värde
Skattad andel SD-röstare	0,2417
Medelfel	0,0147

Det systematiska urvalet gav en skattning på 0,2417 och ett medelfel på 0,0147. Skattningen ligger relativt nära populationsvärdet. Medelfelet är också lågt och ligger på ungefär samma nivå som medelfelet för det proportionellt stratifierade urvalet.

Systematiskt urval är enkelt att genomföra i praktiken och kan ge god precision, särskilt om populationen inte är ordnad på ett sätt som skapar periodicitet i förhållande till urvalsintervallet.

6 Tvåstegsurval med lika sannolikheter

I denna del genomfördes ett tvåstegsurval med lika sannolikheter. I det första steget drogs 50 valdistrikt. I det andra steget drogs 20 individer inom varje valt valdistrikt. Det totala urvalet bestod därmed av ungefär $50 \cdot 20 = 1000$ individer.

Tvåstegsurval är en form av klusterurval, eftersom individer först grupperas i valdistrikt och urvalet sedan sker i två steg. Metoden kan vara praktiskt användbar när det är enklare att först välja geografiska områden och därefter individer inom dessa områden.

För varje valt valdistrikt användes information om antalet individer i distriktet för att skapa ett korrekt survey-designobjekt. Resultatet visas i Tabell 11.

Tabell 11: Skattning av andelen SD-röstare med tvåstegsurval med lika sannolikheter.

Storhet	Värde
Skattad andel SD-röstare	0,2561
Medelfel	0,0222

Tvästegsurvalet med lika sannolikheter gav en skattning på 0,2561 och ett medelfel på 0,0222. Skattningen ligger relativt nära populationsvärdet, men medelfelet är högre än för de tidigare metoderna.

Det högre medelfelet är rimligt eftersom individer inom samma valdistrikt kan antas vara mer lika varandra än individer från olika delar av populationen. Detta innebär att urvalet innehåller mindre oberoende information än ett obundet slumpmässigt urval av individer från hela populationen.

7 Tvåstegsurval med olika sannolikheter

I denna del genomfördes ett tvåstegsurval med olika inklusionssannolikheter, ett så kallat PPS-urval. PPS står för *probability proportional to size*. Det innebär att större valdistrikt hade högre sannolikhet att väljas i det första steget.

I det första steget drogs 50 valdistrikt med sannolikhet proportionell mot valdistriktens storlek. I det andra steget drogs 20 individer inom varje valt valdistrikt. Den totala inklusionssannolikheten för individ i i valdistrikt h kan skrivas som

$$\pi_i = \pi_h \cdot \frac{20}{M_h},$$

där π_h är inklusionssannolikheten för valdistrikt h i första steget och M_h är antalet individer i valdistriktet. Vikten för varje individ definierades som

$$w_i = \frac{1}{\pi_i}.$$

Resultatet visas i Tabell 12.

Tabell 12: Skattning av andelen SD-röstare med PPS-urval.

Storhet	Värde
Skattad andel SD-röstare	0,2388
Medelfel	0,0202

PPS-urvalet gav en skattning på 0,2388 och ett medelfel på 0,0202. Skattningen ligger relativt nära populationsvärdet, men medelfelet är högre än för OSU, systematiskt urval och de stratifierade urvalen.

PPS-urvalet gav dock ett lägre medelfel än tvåstegsurvalet med lika sannolikheter. Detta är rimligt eftersom större valdistrikt ges större sannolikhet att väljas, vilket kan göra urvalet mer representativt än ett tvåstegsurval där alla valdistrikt har samma sannolikhet att väljas.

8 Jämförelse mellan urvalsmetoder

I denna del jämförs skattningarna från de olika urvalsmetoderna med den faktiska andelen SD-röstare bland de röstande i populationen. Populationsvärdet var 0,2485. Jämförelsen fokuserar både på skattningarnas nivå och på deras medelfel.

Tabell 13: Jämförelse mellan olika urvalsmetoder.

Metod	Skattning	Medelfel
OSU efterstratifiering	0,2452	0,0151
Stratifierat proportionellt	0,2443	0,0147
Stratifierat Neyman	0,2260	0,0144
Systematiskt urval	0,2417	0,0147
Tvåstegsurval lika sannolikheter	0,2561	0,0222
PPS-urval	0,2388	0,0202

Av Tabell 13 framgår att de flesta skattningar ligger relativt nära populationsvärdet 0,2485. OSU med efterstratifiering, proportionellt stratifierat urval och systematiskt urval gav mycket liknande skattningar och relativt låga medelfel.

Det stratifierade urvalet med Neyman-allokering gav det lägsta medelfelet i jämförelsen, 0,0144. Detta stämmer med teorin, eftersom Neyman-allokering syftar till att minska variansen genom att fördela fler observationer till strata med större variation. Samtidigt blev själva skattningen från Neyman-urvalet relativt låg i detta stickprov, 0,2260. Detta illustrerar att en metod kan ha låg varians men ändå ge en enskild realisation som avviker från populationsvärdet.

Tvåstegsurvalet med lika sannolikheter gav det högsta medelfelet, 0,0222. Detta är rimligt eftersom individer inom samma valdistrikt kan antas vara mer lika varandra än individer från olika delar av populationen. Därför innehåller ett sådant klusterbaserat urval mindre oberoende information än ett urval där individer dras mer utspritt från hela populationen.

PPS-urvalet gav ett lägre medelfel än tvåstegsurvalet med lika sannolikheter, men fortfarande högre än de enkla och stratifierade urvalen. Att större valdistrikt hade högre sannolikhet att väljas verkar därmed ha förbättrat precisionen något jämfört med tvåstegsurvalet med lika sannolikheter.

Sammanfattningsvis visar jämförelsen att stratifierade urval gav de lägsta medelfelen i denna analys. Särskilt Neyman-allokering framstår som effektiv, eftersom den tog hänsyn till både stratumens storlek och variationen inom strata.

9 Slutlig skattning

Utifrån jämförelsen i avsnitt 7 valdes ett stratifierat urval med Neyman-allokering som slutlig metod. Denna metod gav det lägsta medelfelet i jämförelsen och bedöms därför vara mest effektiv. Eftersom valkretsarna skiljer sig åt i både storlek och variation är geografisk stratifiering rimlig. Neyman-allokering tar dessutom hänsyn till variationen inom respektive stratum, vilket innebär att fler observationer placeras i strata där variationen är större.


Det är dock viktigt att skilja mellan jämförelsen av SD-indikatorn och den slutliga skattningen av partistödet. I jämförelsen ovan skattades andelen SD-röstare med indikatorvariabeln SD. I den slutliga skattningen skattades i stället röstandelarna för de olika riksdagspartierna bland de röstande. Därför behöver inte SD-värdet i den slutliga partitabellen vara exakt samma som SD-skattningen i jämförelsetabellen.

Med det Neyman-allokerade stratifierade urvalet skattades stödet för samtliga riksdagspartier i Skåne. Resultatet visas i Tabell 14.

Tabell 14: Skattat stöd för riksdagspartierna i Skåne med Neyman-allokerat stratifierat urval.

Parti	Skattad andel (%)	Medelfel (%)
Socialdemokraterna	26,61	1,54
Centerpartiet	5,24	0,77
Kristdemokraterna	5,52	0,78
Liberalerna	5,08	0,77
Miljöpartiet	5,08	0,77
Moderaterna	18,12	1,33
Sverigedemokraterna	24,91	1,48
Vänsterpartiet	6,75	0,89

Figur 2 visar samma skattningar grafiskt.



Figur 2: Skattat stöd för riksdagspartierna i Skåne med Neyman-allokerat stratifierat urval.

Av Tabell 14 och Figur 2 framgår att Socialdemokraterna och Sverigedemokraterna skattas ha högst stöd i Skåne. Socialdemokraterna skattas till 26,61 procent och Sverigedemokraterna till 24,91 procent. Moderaterna är det tredje största partiet med en skattad andel på 18,12 procent. Vänsterpartiet skattas till 6,75 procent, medan Centerpartiet, Kristdemokraterna, Liberalerna och Miljöpartiet ligger mellan ungefär 5 och 6 procent.

Sammanfattningsvis framstår det Neyman-allokerade stratifierade urvalet som ett lämpligt val eftersom det gav lägst medelfel i jämförelsen mellan urvalsmetoderna. Samtidigt visar resul-

taten att en enskild skattning fortfarande kan avvika från populationsvärdet till följd av slumpvariation.

10 AI-redogörelse

Claude användes som stöd vid arbetet med kod i den beskrivande statistikdelen, bland annat för att sammanställa antal och andelar röster per parti med hjälp av `dplyr`. Claude användes även som stöd vid felsökning av kod. ChatGPT användes som stöd för språkgranskning, strukturering av rapporttext samt för att skapa och justera figurer i $\text{\LaTeX}$.